

DATA UNDERSTANDING REPORT

Industry Simulation Program – Data Analyst

Week: 02

Day: 03

Topic: Data Understanding

Nama: Maulana Aldi Pradana

Dataset: 100000 Sales Records

1. Nama Dataset

100000 Sales Records

2. Sumber

Dataset diperoleh dari website **ExcelX – Practice Data**.

Link Dataset:

<https://excelx.com/practice-data/sales-retail/>

Format Dataset: CSV

3. Deskripsi

Dataset **100000 Sales Records** merupakan dataset simulasi transaksi penjualan yang terdiri dari **100.000 data transaksi** dari berbagai negara dan wilayah di dunia. Setiap baris data merepresentasikan satu transaksi penjualan yang memuat informasi mengenai wilayah penjualan, negara, kategori produk, saluran penjualan, prioritas pesanan, tanggal pemesanan, tanggal pengiriman, jumlah unit terjual, harga satuan, biaya satuan, total pendapatan, total biaya, dan total keuntungan.

Dataset ini banyak digunakan sebagai media pembelajaran Data Analysis karena memiliki struktur data yang lengkap dan mencakup berbagai tipe data, baik kategorikal maupun numerik.

Dengan karakteristik tersebut, dataset ini sangat sesuai untuk latihan Exploratory Data Analysis (EDA), Data Cleaning, Visualisasi Data, serta pembuatan Dashboard.

4. Tujuan Dataset

Dataset ini digunakan sebagai media pembelajaran untuk memahami proses analisis data menggunakan Python. Analisis terhadap dataset bertujuan untuk:

- Mempelajari struktur dataset sebelum dilakukan analisis.
 - Melakukan Exploratory Data Analysis (EDA).
 - Mengidentifikasi pola penjualan berdasarkan produk, wilayah, dan negara.
 - Menganalisis pendapatan (Revenue), biaya (Cost), dan keuntungan (Profit).
 - Menjadi dasar dalam pembuatan dashboard interaktif dan business insight.
-

5. Jumlah Data

Berdasarkan hasil eksplorasi menggunakan library Pandas, diperoleh informasi sebagai berikut:

Informasi	Nilai
Jumlah Baris	100.000
Jumlah Kolom	14
Memory Usage	10.7 MB

Dataset terdiri atas **100.000 baris data** dan **14 variabel** yang siap digunakan untuk proses analisis lebih lanjut.

6. Jumlah Variabel

Dataset memiliki **14 variabel**, yaitu:

No Nama Variabel

- 1 Region
- 2 Country
- 3 Item Type
- 4 Sales Channel

No Nama Variabel

- 5 Order Priority
- 6 Order Date
- 7 Order ID
- 8 Ship Date
- 9 Units Sold
- 10 Unit Price
- 11 Unit Cost
- 12 Total Revenue
- 13 Total Cost
- 14 Total Profit

Variabel-variabel tersebut terdiri atas data kategorikal, numerik, dan tanggal yang akan digunakan dalam proses analisis.

7. Target Analysis

Analisis terhadap dataset ini difokuskan untuk menjawab beberapa pertanyaan bisnis berikut:

- Produk apa yang memiliki jumlah penjualan terbesar?
- Negara atau wilayah mana yang menghasilkan pendapatan tertinggi?
- Bagaimana distribusi keuntungan berdasarkan kategori produk?
- Bagaimana perbandingan penjualan melalui saluran **Online** dan **Offline**?
- Bagaimana hubungan antara jumlah unit terjual dengan total keuntungan?

Pertanyaan-pertanyaan tersebut akan menjadi dasar dalam proses Exploratory Data Analysis (EDA) pada tahap berikutnya.

8. Potensi Insight

Dataset ini memiliki potensi menghasilkan berbagai insight bisnis, antara lain:

- Mengetahui kategori produk dengan performa penjualan terbaik.
- Mengidentifikasi wilayah dan negara dengan kontribusi pendapatan terbesar.
- Menganalisis distribusi keuntungan pada setiap kategori produk.
- Membandingkan performa penjualan berdasarkan saluran penjualan (Online dan Offline).
- Mengidentifikasi pola transaksi berdasarkan waktu setelah data tanggal dikonversi ke format **datetime**.

- Menjadi dasar dalam penyusunan dashboard bisnis untuk mendukung proses pengambilan keputusan.
-

9. Kelebihan Dataset

Dataset ini memiliki beberapa kelebihan, yaitu:

- Memiliki jumlah data yang besar, yaitu **100.000 transaksi**, sehingga cukup representatif untuk proses analisis.
 - Tidak ditemukan **missing value** pada hasil pemeriksaan awal menggunakan `df.info()`.
 - Memiliki kombinasi data kategorikal dan numerik yang lengkap.
 - Cocok digunakan untuk latihan Data Analysis, Data Cleaning, EDA, Visualisasi Data, hingga Dashboard.
 - Mudah diproses menggunakan library Python seperti Pandas, Matplotlib, dan Seaborn.
-

10. Kekurangan Dataset

Meskipun memiliki struktur yang baik, dataset ini masih memiliki beberapa keterbatasan, yaitu:

- Kolom **Order Date** dan **Ship Date** masih bertipe **object** sehingga perlu dikonversi menjadi tipe **datetime** sebelum dilakukan analisis berbasis waktu.
 - Dataset tidak memiliki informasi pelanggan sehingga analisis perilaku pelanggan (Customer Analysis) tidak dapat dilakukan.
 - Tidak tersedia informasi mengenai diskon, metode pembayaran, maupun pengiriman sehingga analisis bisnis menjadi terbatas.
 - Dataset merupakan data simulasi sehingga tidak sepenuhnya merepresentasikan kondisi bisnis di dunia nyata.
-

Kesimpulan

Berdasarkan proses **Data Understanding**, dataset **100000 Sales Records** memiliki struktur data yang baik dan siap digunakan untuk tahap analisis selanjutnya. Dataset terdiri atas **100.000 baris** dan **14 variabel** dengan kombinasi data kategorikal dan numerik yang lengkap. Hasil pemeriksaan awal menunjukkan bahwa seluruh kolom memiliki **100.000 nilai non-null**, sehingga tidak ditemukan missing value pada tahap awal.

Selain itu, diperoleh informasi bahwa kolom **Order Date** dan **Ship Date** masih bertipe **object**, sehingga perlu dilakukan konversi menjadi **datetime** pada tahap Data Cleaning agar dapat digunakan dalam analisis berbasis waktu.

Secara keseluruhan, dataset ini dinilai layak untuk dilanjutkan ke tahap **Data Profiling** guna mengevaluasi kualitas data secara lebih mendalam sebelum dilakukan proses Data Cleaning, Exploratory Data Analysis (EDA), dan Visualisasi Data.