

DATASET SUMMARY

Industry Simulation Program – Data Analyst

Week : 02

Day : 04


Materi : Eksplorasi Awal Dataset (Dataset Summary)

Nama : Maulana Aldi Pradana

Dataset : 100000 Sales Records

1. Screenshot Dataset

Berikut merupakan tampilan awal dataset menggunakan fungsi `head()` pada library Pandas.



	Region	Country	Item Type	Sales Channel	Order Priority	Order Date	Order ID	Ship Date	Units Sold	Unit Price	Unit Cost	Total Revenue	Total Cost	Total Profit
0	Middle East and North Africa	Azerbaijan	Snacks	Online	C	10/8/2014	535113847	10/23/2014	934	152.58	97.44	142509.72	91008.96	51500.76
1	Central America and the Caribbean	Panama	Cosmetics	Offline	L	2/22/2015	874708545	2/27/2015	4551	437.20	263.33	1989697.20	1198414.83	791282.37
2	Sub-Saharan Africa	Sao Tome and Principe	Fruits	Offline	M	12/9/2015	854349935	1/18/2016	9986	9.33	6.92	93169.38	69103.12	24066.26
3	Sub-Saharan Africa	Sao Tome and Principe	Personal Care	Online	M	9/17/2014	892836844	10/12/2014	9118	81.73	56.67	745214.14	516717.06	228497.08
4	Central America and the Caribbean	Belize	Household	Offline	H	2/4/2010	129280602	3/5/2010	5858	668.27	502.54	3914725.66	2943879.32	970846.34

Hasil tersebut menunjukkan lima baris pertama dari dataset yang berisi informasi mengenai wilayah (Region), negara (Country), jenis produk (Item Type), saluran penjualan (Sales Channel), prioritas pesanan (Order Priority), tanggal pemesanan (Order Date), tanggal pengiriman (Ship Date), jumlah unit terjual (Units Sold), harga satuan (Unit Price), biaya satuan (Unit Cost), total pendapatan (Total Revenue), total biaya (Total Cost), dan total keuntungan (Total Profit).

2. Statistik Dasar

Statistik dasar diperoleh menggunakan fungsi `describe()` pada library Pandas.

Generate summary statistics for numerical columns.

```
df.describe()
```

	Order ID	Units Sold	Unit Price	Unit Cost	Total Revenue	Total Cost	Total Profit
count	1.000000e+05	100000.000000	100000.000000	100000.000000	1.000000e+05	1.000000e+05	1.000000e+05
mean	5.503956e+08	5001.446170	266.703989	188.019711	1.336067e+06	9.419755e+05	3.940912e+05
std	2.593219e+08	2884.575424	216.940081	175.706023	1.471768e+06	1.151828e+06	3.795986e+05
min	1.000089e+08	1.000000	9.330000	6.920000	1.866000e+01	1.384000e+01	4.820000e+00
25%	3.260464e+08	2505.000000	109.280000	56.670000	2.797533e+05	1.629283e+05	9.590000e+04
50%	5.477185e+08	5007.000000	205.700000	117.110000	7.898916e+05	4.679374e+05	2.836575e+05
75%	7.750785e+08	7495.250000	437.200000	364.690000	1.836490e+06	1.209475e+06	5.683841e+05
max	9.999965e+08	10000.000000	668.270000	524.960000	6.682700e+06	5.249075e+06	1.738700e+06

Berdasarkan hasil statistik deskriptif, dataset terdiri dari **100.000 data transaksi**. Variabel numerik seperti **Units Sold**, **Unit Price**, **Unit Cost**, **Total Revenue**, **Total Cost**, dan **Total Profit** memiliki nilai minimum, maksimum, rata-rata (mean), median (50%), serta standar deviasi yang dapat digunakan sebagai dasar dalam proses analisis selanjutnya.

3. Jumlah Missing Value

Pemeriksaan missing value dilakukan menggunakan fungsi `df.isnull().sum()`.

```
df.isnull().sum()
```


Region	0
Country	0
Item Type	0
Sales Channel	0
Order Priority	0
Order Date	0
Order ID	0
Ship Date	0
Units Sold	0
Unit Price	0
Unit Cost	0
Total Revenue	0
Total Cost	0
Total Profit	0

dtype: int64

Hasil pemeriksaan menunjukkan bahwa seluruh kolom memiliki nilai **0**, sehingga **tidak ditemukan missing value** pada dataset. Hal ini menunjukkan bahwa dataset memiliki kualitas data awal yang baik dan tidak memerlukan penanganan missing value pada tahap Data Cleaning.

4. Jumlah Data Unik

Jumlah data unik diperoleh menggunakan fungsi `df.nunique()`.



```
df.nunique()
```

	0
Region	7
Country	185
Item Type	12
Sales Channel	2
Order Priority	4
Order Date	2766
Order ID	100000
Ship Date	2813
Units Sold	9998
Unit Price	12
Unit Cost	12
Total Revenue	68312
Total Cost	68248
Total Profit	68269

dtype: int64

Hasil analisis menunjukkan bahwa setiap variabel memiliki jumlah nilai unik yang berbeda sesuai karakteristik data. Kolom **Order ID** memiliki **100.000 nilai unik**, yang menunjukkan bahwa setiap transaksi memiliki identitas yang berbeda. Sementara itu, variabel kategorikal seperti **Sales Channel**, **Order Priority**, **Region**, dan **Item Type** memiliki jumlah kategori yang lebih sedikit karena digunakan secara berulang pada setiap transaksi.

5. Insight Awal

Berdasarkan hasil eksplorasi awal dataset, diperoleh beberapa insight sebagai berikut.

- Dataset terdiri dari **100.000 transaksi penjualan** dengan **14 variabel**.
- Tidak ditemukan **missing value** sehingga kualitas data awal tergolong baik.
- Dataset memiliki kombinasi data kategorikal dan numerik yang lengkap sehingga sesuai untuk proses Exploratory Data Analysis (EDA).
- Kolom **Order Date** dan **Ship Date** masih bertipe **object**, sehingga perlu dikonversi menjadi tipe **datetime** pada tahap Data Cleaning agar dapat digunakan untuk analisis berbasis waktu.
- Dataset memiliki potensi untuk menghasilkan berbagai insight bisnis, seperti analisis penjualan berdasarkan wilayah, negara, kategori produk, saluran penjualan, serta analisis pendapatan dan keuntungan.

Kesimpulan

Berdasarkan proses eksplorasi awal menggunakan library Pandas, dataset **100000 Sales Records** memiliki struktur data yang lengkap dan kualitas data yang baik. Seluruh variabel berhasil dibaca dengan benar dan tidak ditemukan missing value pada tahap pemeriksaan awal. Dataset ini siap digunakan pada tahap berikutnya, yaitu **Data Profiling** dan **Data Cleaning**, sebelum dilakukan proses Exploratory Data Analysis (EDA) yang lebih mendalam.